DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

in collaborazione con

Istituto di Informatica e Telematica

UNIVERSITÀ DI PISA

Master Universitario di I Livello in Cybersecurity

Corso "Cyber Intelligence": esercitazione su ES e Kibana

Tiziano Fagni
IIT,CNR
tiziano.fagni@iit.cnr.it

DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

in collaborazione con

Istituto di Informatica e Telematica

UNIVERSITÀ DI PISA

Master Universitario di I Livello in Cybersecurity

Lezione del 11/6/2022

Esercizio 1

Obiettivo

Sfruttando il template presente sul file “TwitterMappingFromScript.json” in “cint/esercitazione/elastic/mapping_2.0”, creare un nuovo mapping per ES che consideri anche i campi di arricchimento definiti negli Esercizi 4 e 5 su NiFi. I campi nuovi fanno riferimento a questi dati:

```
"politicians": {
    "polarity": "-1",
    "names": ["Salvini"]
},
"webpage":{
    "url":"https://t.co/6wixF7WHyq",
    "title":"PesNew Era su Twitter...",
    "content":"Ora sei..."
}
```

Sfruttare https://www.elastic.co/guide/en/elasticsearch/reference/current/mapping-types.html

Esercizi su query

Trovate la documentazione di Elasticsearch sulle query qui: https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl.html

Tipi di query che vedremo:

- Full text queries
- Term level queries

Faremo le nostre query sull'indice "twitter_data" creato dal dataflow "TwitterForQueries".

Full text queries: “match” query

```
GET /<index-name>/_search
{
  "from" : 0,
  "size" : 100,
  "query": {
        "match" : {
            "message" : {
                "query" : "this is a test",
                "operator" : "and"
            }
        }
    }
}
```

Cerca le parole specificate dalla keyword “query” nel campo padre. Posso dire se cercarle in “and” oppure “or” tramite la keyword “operator”.

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-match-query.html

Esercizio

Sfruttando la “match” query, cercare tutti i tweet che verificano le query:

1. frase “putin guerra” con parole in “and” sul campo contenente il tweet.
2. frase “conte governo” con parole in “or” sul campo contenente il tweet.
3. frase “covid vaccino” con parole in “and” sul campo che fa riferimento il contenuto della pagina Web collegata.

Full text queries: “match phrase” query

```
GET /_search
{
    "query": {
        "match_phrase" : {
            "message" : {
                "query": "this is a test",
                "slop": 0
            }
        }
    }
}
```

Cerca il matching per la frase specificata nel campo indicato. Con il parametro “slop” si può indicare quanto preciso può essere fatto il matching considerando l’ordine delle parole.

Il parametro “slop” cerca di rispondere a questa domanda

“By how far apart we mean how many times do you need to move a term in order to make the query and document match?”

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-match-query-phrase.html

https://www.elastic.co/guide/en/elasticsearch/guide/current/slop.html

Esercizio

Sfruttando la “match phrase” query e usando un campo a vostra scelta, cercare tutti i tweet che verificano le query:

1. “pd draghi” con vari valori di “slop”.

2. “salvini lega” con vari valori di “slop”.

Full text queries: “match phrase prefix” query

```
GET /_search
{
    "query": {
        "match_phrase_prefix" : {
            "message": {
                "query" : "this is a t",
                "slop": 0,
                "max_expansions" : 50
            }
        }
    }
}
```

Cerca il matching nel campo indicato per la frase specificata facendo l’espansione dell’ultimo termine.

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-match-query-phrase-prefix.html

Esercizio

Sfruttando la “match phrase prefix” query e usando un campo a vostra scelta, cercare tutti i tweet che verificano le query:

1. “conte gov” con vari valori di “slop”.
2. “governo c” con vari valori di “slop”.

E’ possibile utilizzare sia la scheda “Dev tools” sia la scheda “Discover”

Full text queries: Multi Match query

```
GET /_search
{
  "query": {
    "multi_match" : {
      "query":      "brown fox",
      "type":       "best_fields",
      "fields":     [ "subject^3", "message" ],
    }
  }
}
```

Stessa semantica della “match” query ma con la possibilità di utilizzare più campi di ricerca e combinare gli score.

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-multi-match-query.html

Esercizio

Sfruttando la “multi match” query, provate a cercare qualcosa sui campi “text” e “webpage.content”

- assegnando 3 volte più importanza a quello che trovate in “webpage.content”.
- provando a combinare lo score finale sfruttando le diverse policy disponibili (vedi https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-multi-match-query.html).

Full text queries: “query string” query

Si usa il **“query string format”** per formulare le query

```
GET /_search
{
    "query": {
        "query_string" : {
            "default_field" : "content",
            "query" : "(this AND that) OR thus",
            "default_operator" : "OR"
        }
    }
}
```

Molti altri parametri disponibili, vedere
https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-query-string-query.html

Query string format

- where the `status` field contains `active`

```
status:active
```

- where the `title` field contains `quick` or `brown`. If you omit the OR operator the default operator will be used

```
title:(quick OR brown)
title:(quick brown)
```

- where the `author` field contains the exact phrase `"john smith"`

```
author:"John Smith"
```

- where any of the fields `book.title`, `book.content` or `book.date` contains `quick` or `brown` (note how we need to escape the `*` with a backslash):

```
book.\*:(quick brown)
```

- where the field `title` has any non-null value:

```
_exists_:title
```

Query string format (2)

- All days in 2012:

```
date:[2012-01-01 TO 2012-12-31]
```

- Numbers 1..5

```
count:[1 TO 5]
```

- Tags between `alpha` and `omega`, excluding `alpha` and `omega`:

```
tag:{alpha TO omega}
```

- Numbers from 10 upwards

```
count:[10 TO *]
```

- Dates before 2012

```
date:{* TO 2012-01-01}
```

Query string format (3)

Ranges with one side unbounded can use the following syntax:

```
age:>10
age:>=10
age:<10
age:<=10
```

NOTE

To combine an upper and lower bound with the simplified syntax, you would need to join two clauses with an `AND` operator:

```
age:(>=10 AND <20)
age:(+>=10 +<20)
```

```
quick brown +fox -news
```

states that:

- `fox` must be present
- `news` must not be present
- `quick` and `brown` are optional — their presence increases the relevance

Query string format (4)

Multiple terms or clauses can be grouped together with parentheses, to form sub-queries:

```
(quick OR brown) AND fox
```

Groups can be used to target a particular field, or to boost the result of a sub-query:

```
status:(active OR pending) title:(full text search)^2
```

E’ possibile fare molte altra cose come ricerche fuzzy, di prossimità, con boosting, ecc.!

La documentazione completa è disponibile qui: https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-query-string-query.html#query-string-syntax

Esercizio

Dal tab “Discover” di Kibana provare a recuperare i tweet che matchano le condizioni:

1. Autore del tweet con numero di follower tra 50 e 500.
2. Testo del tweet che contiene “russia o putin” e che il contenuto della pagina Web contiene “gas e europa”.
3. Descrizione dell’utente che contiene qualsiasi prefisso “euro” e numero di tweet prodotti compresi tra 500 e 1000

Term queries

The `term` query finds documents that contain the **exact** term specified in the inverted index. For instance:

```
POST _search
{
  "query": {
    "term" : { "user" : "Kimchy" } ❶
  }
}
```

Filters documents that have fields that match any of the provided terms (**not analyzed**). For example:

```
GET /_search
{
    "query": {
        "terms" : { "user" : ["kimchy", "elasticsearch"]}
    }
}
```

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-term-query.html

Term queries (2)

```
GET _search
{
    "query": {
        "range" : {
            "age" : {
                "gte" : 10,
                "lte" : 20,
                "boost" : 2.0
            }
        }
    }
}
```

```
GET _search
{
    "query": {
        "range" : {
            "date" : {
                "gte" : "now-1d/d",
                "lt" :  "now/d"
            }
        }
    }
}
```

https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-range-query.html

Altri tipi di term queries utili

- exists query: verifica la presenza di un campo in un documento
- fuzzy query: cerca documenti con termini simili a quello speicificato in query sfruttando similarità basata su Levenshtein edit distance
- ids query: ritorna tutti i documenti che matchano gli ID specificati
- regexp query: ritorna tutti i documenti che matchano una regexp

Per tutto il resto...

- **Query DSL**
  - Query and filter context
  - Match All Query
  - + Full text queries
  - + Term level queries
  - + Compound queries
  - + Joining queries
  - + Geo queries
  - + Specialized queries
  - + Span queries
  - Minimum Should Match
  - Multi Term Query Rewrite

C’è la documentazione!

Guardate a partire da https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl.html

Lezione del 18/6/2022

Creazione e gestione Space su Kibana

Gli Spaces permettono di organizzare i contenuti su Kibana creando dei contenitori logici sotto cui raggruppare “Index Patterns”, viste tabellari, visualizzazioni e dashboard.

Per creare e gestire uno Space andare qui

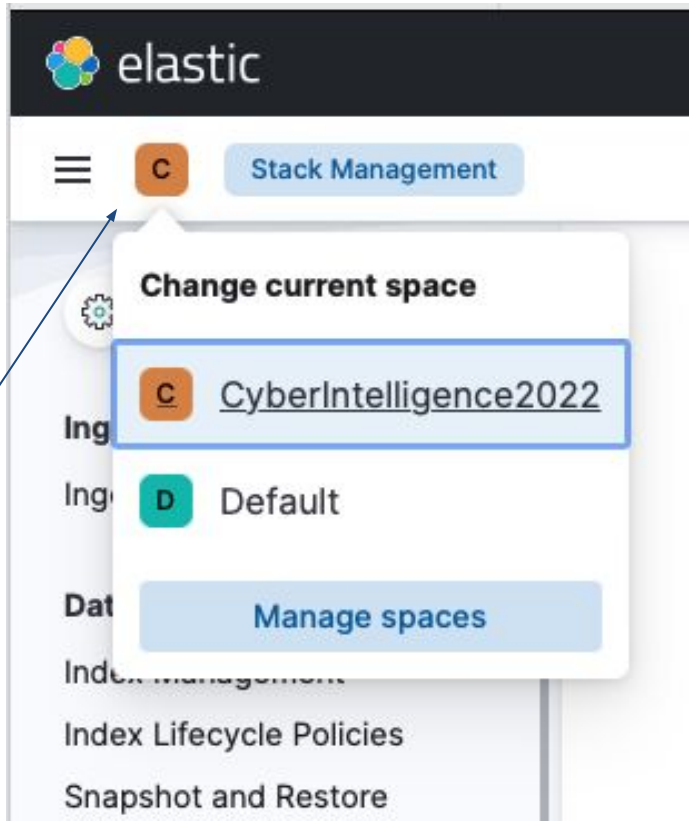

Gli indici sono sempre condivisi tra gli Space ma gli Index Patterns no!

Query salvate

Dal tab “Discover” è possibile creare viste tabellari specifiche che visualizzano i dati con eventuali filtri applicati.

- Creare una vista che riporta “nome autore”, “testo del tweet” e “numero di follower”
- Creare una vista che riporta “nome autore”, “testo del tweet” e “titolo pagina Web esterna” sui tweet prefitrati che contengono sicuramente un link a un articolo esterno.

Visualizzazione 1a e 1b

Componente “Tag Cloud”

Visualizzare i 10 autori più attivi e i 10 account più menzionati sull’insieme di tweet contenuti nell’indice “twitter_data”

a)

b)

Visualizzazione 1c

Visualizzare i termini più utilizzati nel titolo della pagina Web esterna ordinati per popolarità dell'utente (numero di followers)

- Si aggregano i dati per "webpage.title"
- Si usa come metrica di ordinamento la media di user.followers_count

Visualizzazione 2

Componente “Vertical Bar”

Visualizzare a intervalli di 1 minuto la media e la mediana del numero di aggiornamenti di stato degli utenti che twittano.

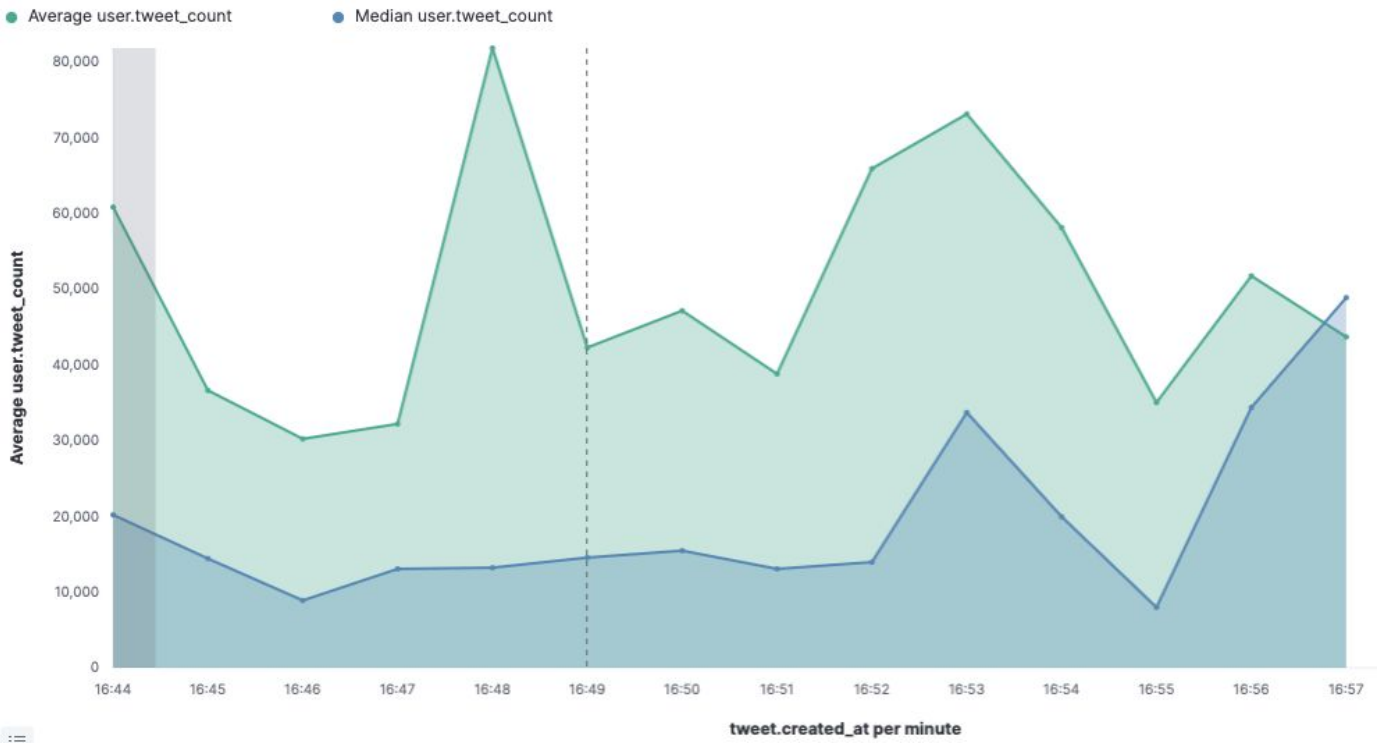

Visualizzazione 3

Componente “Heat Map”
Realizzare una heatmap che metta in relazione il campo “user.followers_count” con il campo “user.statuses_count”.

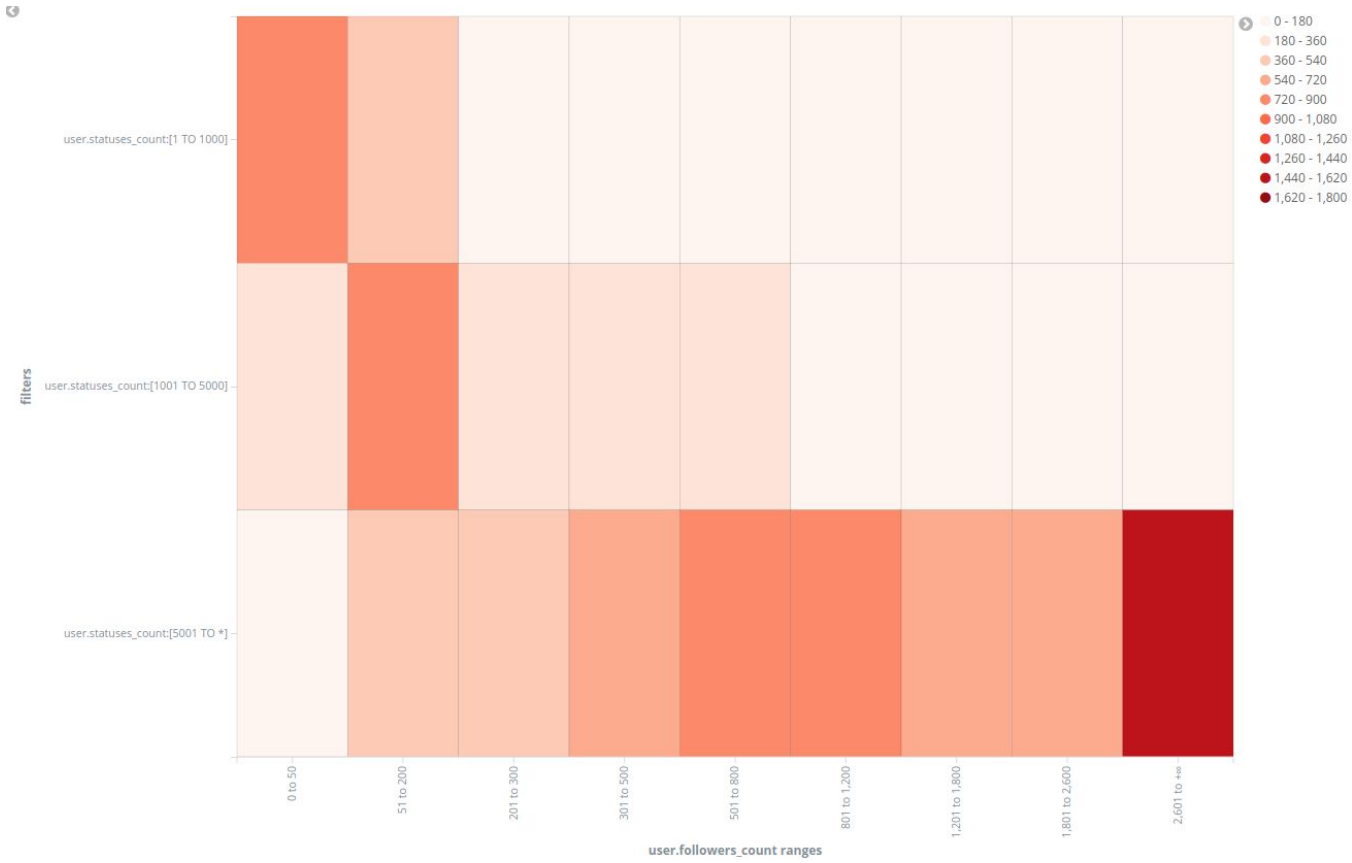

Visualizzazione 4

Componente “Map”
Utilizzando l’indice “earthquakes” creato con il flusso “EarthquakesESIngester”, visualizzare i terremoti occorsi nel corso degli anni sfruttando i layer per “Clusters and grid”, “Heatmaps” e “Documents”

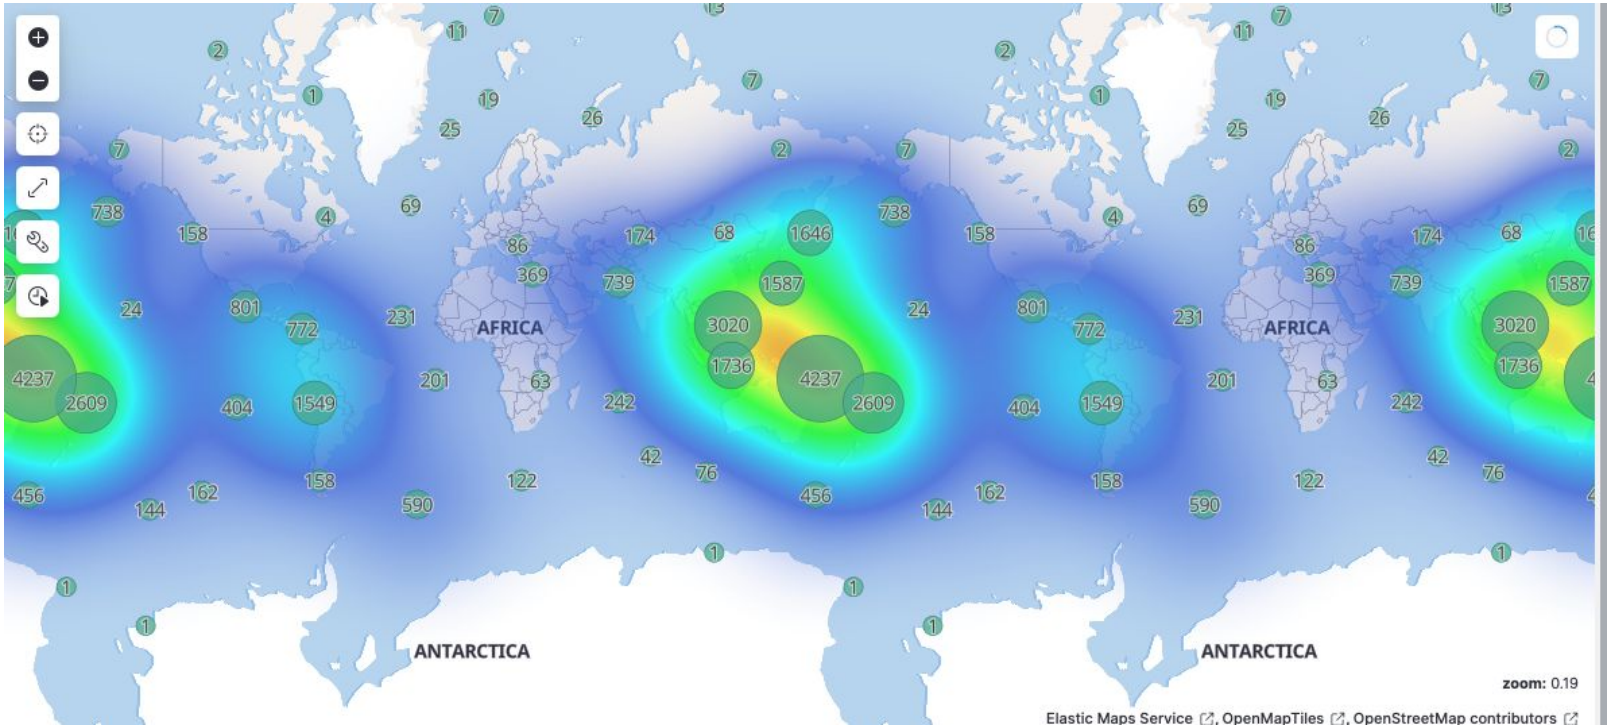

Visualizzazione 5

Componente “Goal”

Monitorare negli ultimi 15 minuti l’obiettivo di avere almeno “n” articoli Web distinti postati ogni 5 minuti.

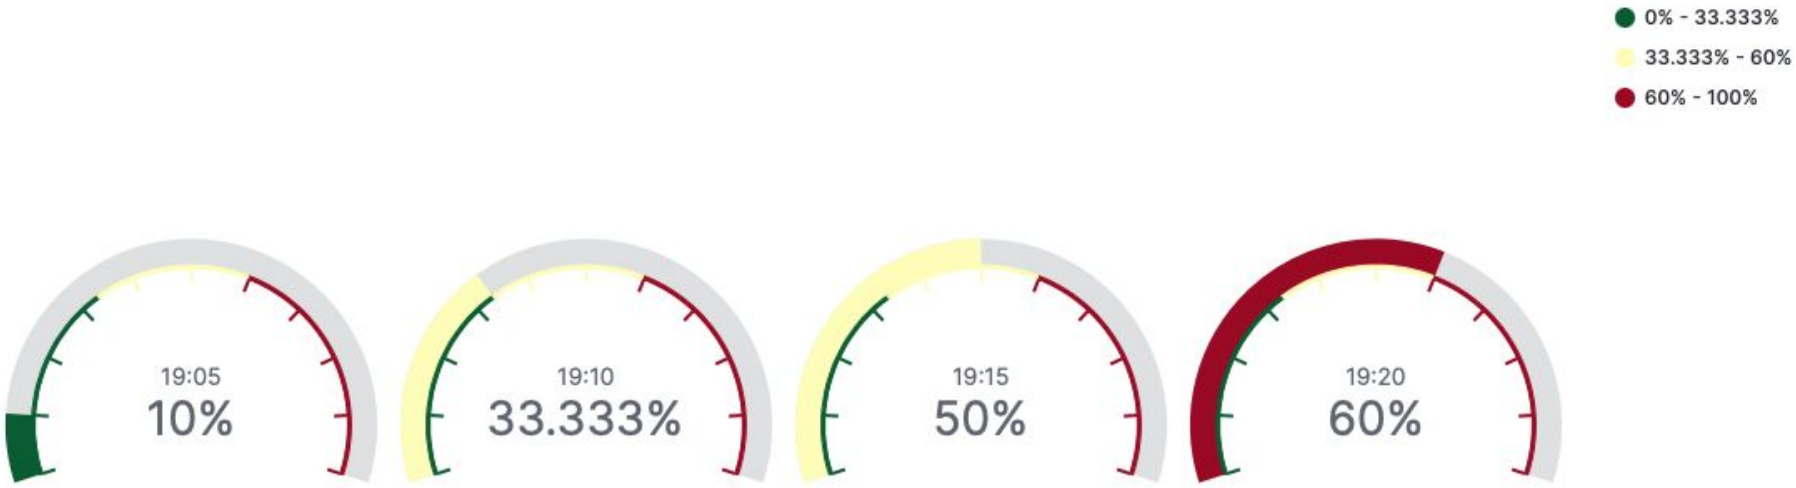

Visualizzazione 6

Componente “Vertical Bar”

Visualizzare negli ultimi 15 minuti i tweet arrivati comparando quelli che contengono “Putin” ma non “guerra” oppure “ucraina” oppure “Zelenski”.

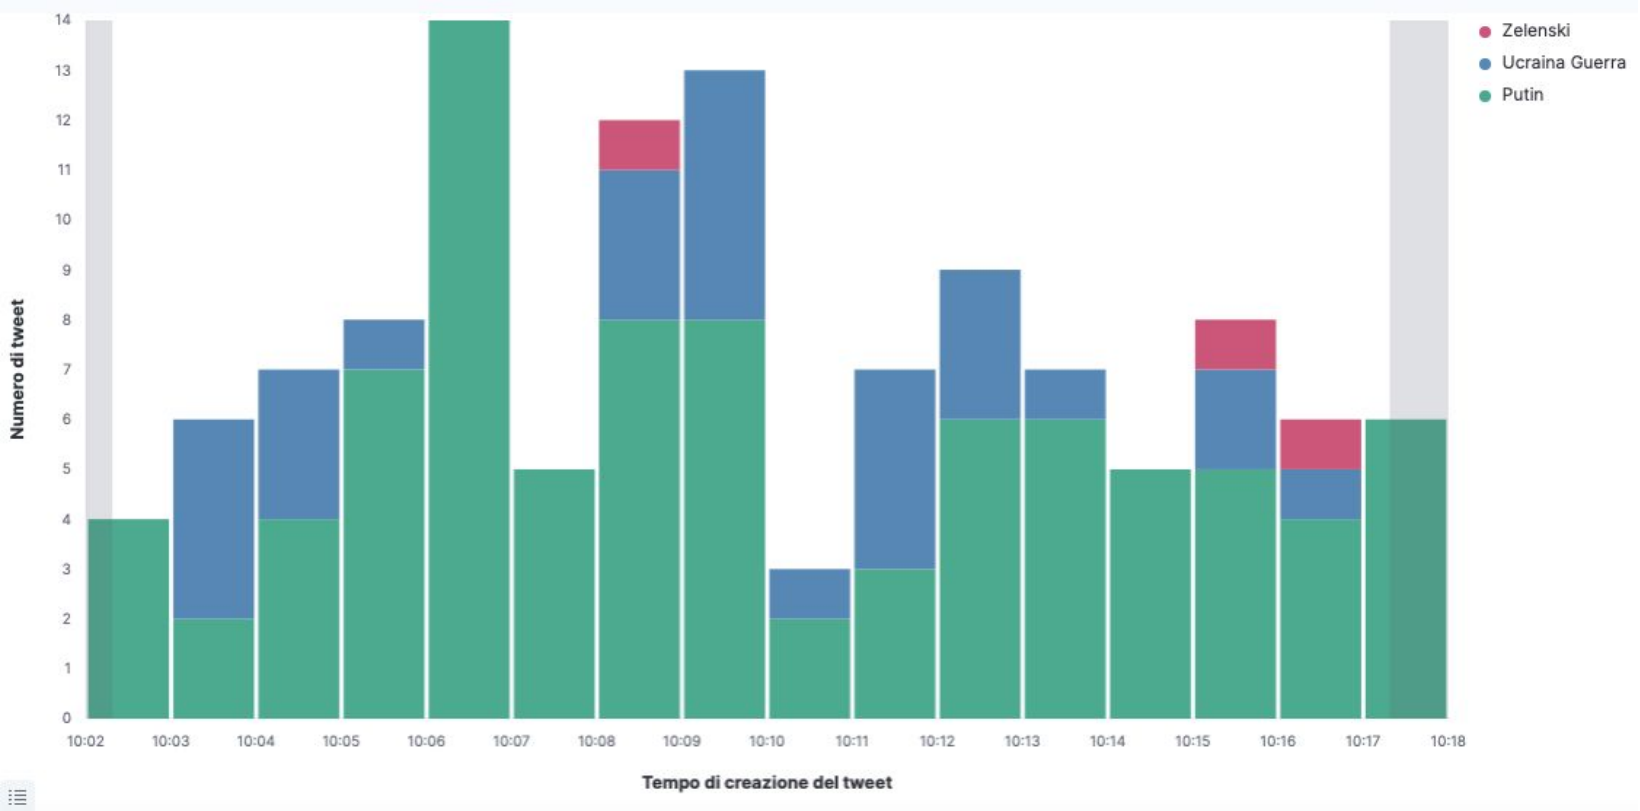

Visualizzazione 7

Componente “Pie”

Visualizzare negli ultimi 15 m come si distribuiscono su una torta gli utenti “non popolari”, “normali” e “popolari”. Definire range opportuni su “user.followers_count”.

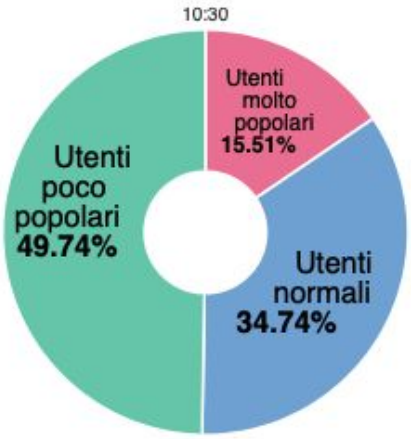

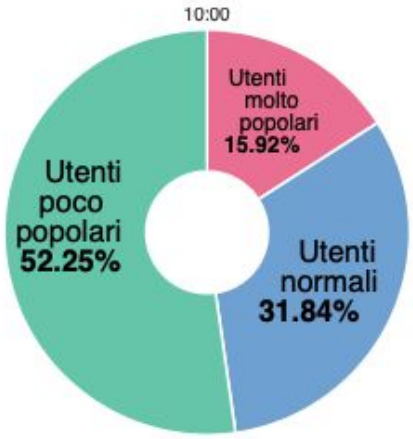

Visualizzazione 8

Usare la modalità “Lens” per creare una tabella riassuntiva che mostri minuto per minuto la media della polarità dei tweet, la media del numero di followers degli autori e la media del numero di following degli autori.

tweet.create	Avg polarity	Avg follower	Avg following
10:20	-0.214	259	1,048.893
10:21	0.098	592	1,092.148
10:22	0.098	590	1,762.843
10:23	-0.085	461	1,910.458
10:24	-0.29	725.5	1,204.29
10:25	-0.362	202	863.207
10:26	-0.324	776.5	1,062.838
10:27	-0.291	850	1,405.164
10:28	-0.057	793	1,596.157

Visualizzazione 9

Sfruttare Lens per visualizzare nello stesso grafico l'andamento del sentiment (max positivo e max negativo) minuto per minuto.

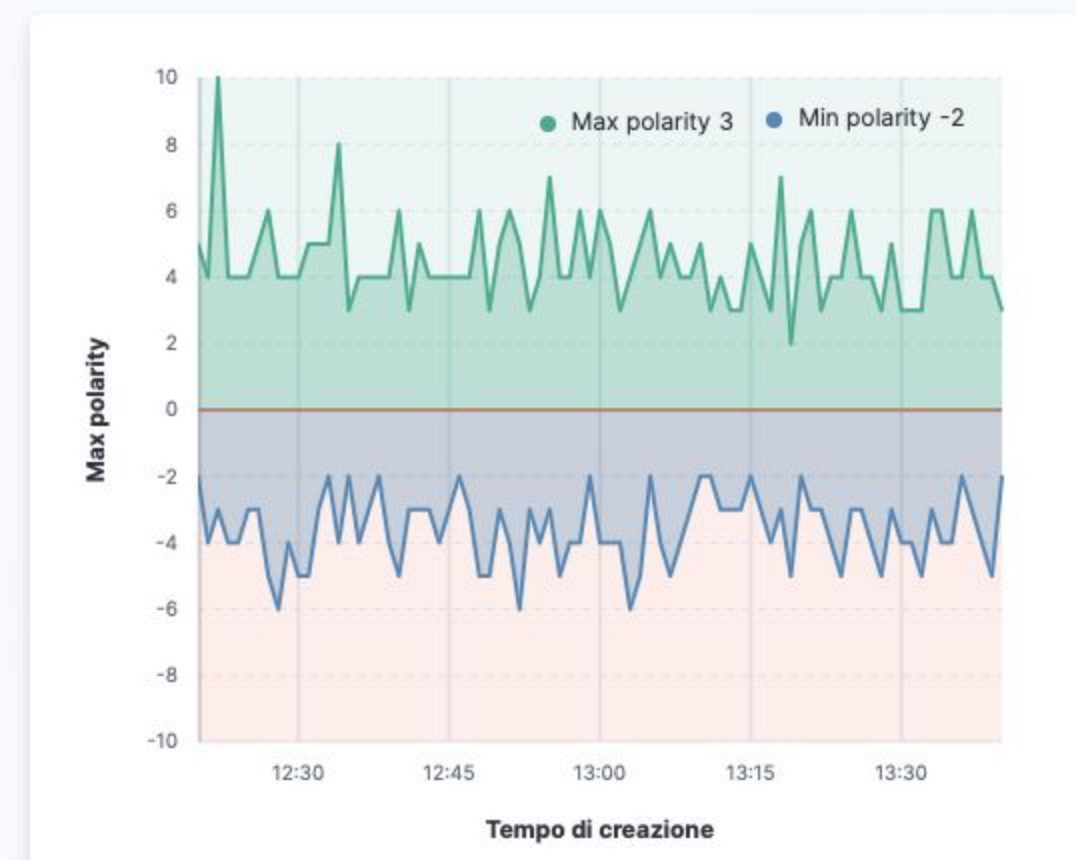

Adesso costruiamo una bella dashboard...

Potete usare *ricerche* e *visualizzazioni* salvate oppure crearle al volo, oltre che filtri dinamici

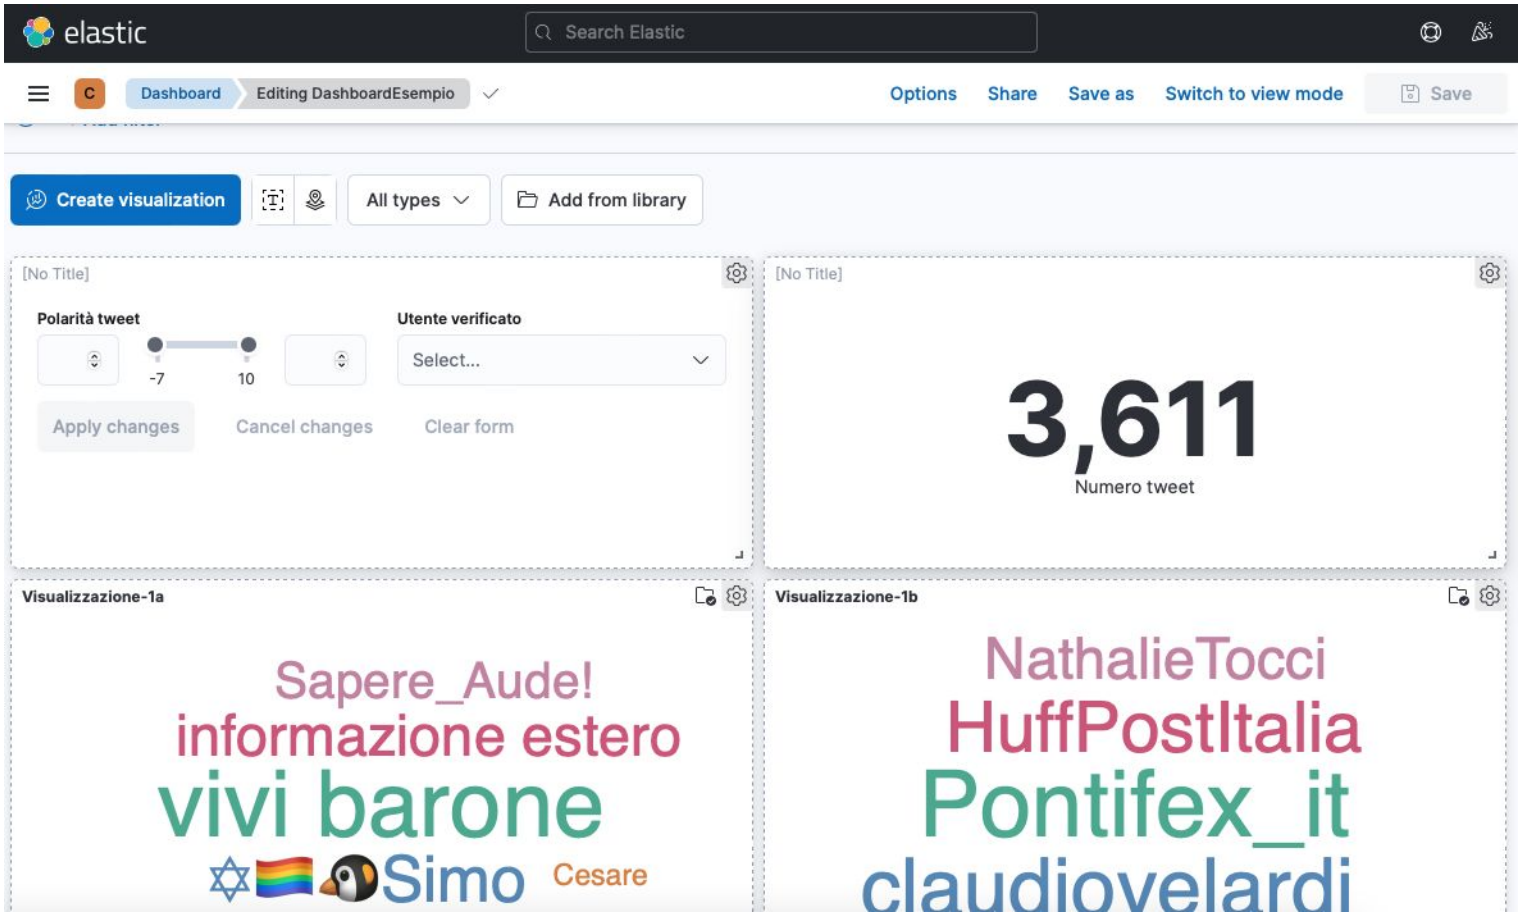

Ok, questo è tutto che che vi serve per fare il vostro bel progettone finale!

Se avete dubbi o domande chiedete pure! :-)

Esercizio 2

Sfruttando il dataflow NiFi definito nell'Esercizio6ForES di Nifi, verificate come cambiano i dati memorizzati in ES, cambiando nel mapping il valore "dynamic" tra "false", "true" e "strict".

Traccia:

- Cancellare eventuale indice esistente.
- Impostare il valore di "dynamic" desiderato nel file di mapping e creare il nuovo indice.
- Caricare qualche dato su ES sfruttando il dataflow di Esercizio6ForES.

https://www.elastic.co/guide/en/elasticsearch/reference/current/dynamic.html

Prima di passare alle visualizzazioni Kibana...

- Creare un nuovo indice sfruttando il file “ItalianTweetsMapping.json” disponibile nella cartella “elastic”.
- Aprire il progetto NiFi “IngesterGeolocatedItalianTweets”, configurare GetTwitter, quindi eseguire il progetto.
- Lasciatelo in Run così l’indice si comincia a riempire.

Timelion: visualizzare velocemente time series

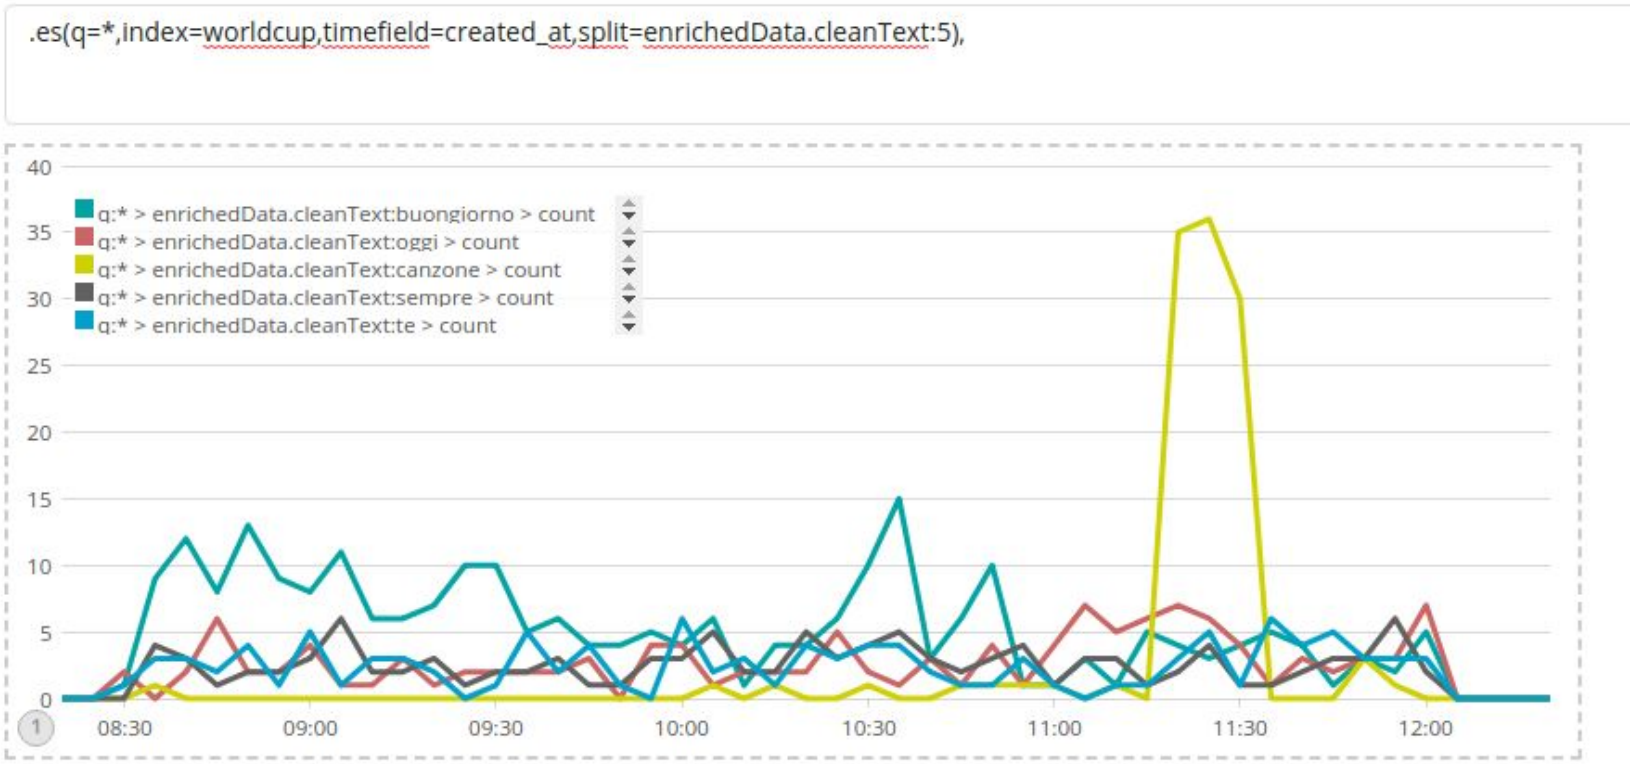

Documentazione: https://www.elastic.co/guide/en/kibana/current/timelion.html
Tutorial: https://www.elastic.co/blog/timelion-tutorial-from-zero-to-hero